

变分推断

1. 背景 (Background)

1.1 频率派 vs 贝叶斯派 (Frequentist vs Bayesian)

核心区别在于对参数的看法以及随之而来的问题类型：

- 频率派视角 (Frequentist) → 优化问题 (Optimization Problem)
 - 参数 w 被视为未知的常量。
 - 例子 1: 回归 (Regression)
 - 模型 (Model): $f(w) = w^T x$
 - 损失函数 (Loss Function): $L(w) = \sum_{i=1}^N \|w^T x_i - y_i\|^2$
 - 算法 (Algorithm): $\hat{w} = \arg \min L(w)$
 - 求解:
 - 解析解 (Analytic Solution): $\frac{\partial L(w)}{\partial w} = 0 \Rightarrow w^* = (X^T X)^{-1} X^T Y$
 - 数值解 (Numerical Solution): 梯度下降 (GD), 随机梯度下降 (SGD)
 - 例子 2: SVM (支持向量机)
 - 模型: $f(w) = \text{sign}(w^T x + b)$
 - 损失函数: $\min \frac{1}{2} w^T w$ s.t. $y_i(w^T x_i + b) \geq 1$ (凸优化 Convex Optimization)
 - 算法: 二次规划 (QP), 拉格朗日对偶 (Lagrange Duality)
- 贝叶斯视角 (Bayesian) → 积分问题 (Integration Problem)
 - 参数 θ 被视为随机变量。
 - 贝叶斯定理 (Bayes' Theorem):
$$P(\theta|X) = \frac{P(X|\theta) \cdot P(\theta)}{P(X)}$$
 - $P(\theta|X)$: 后验 (Posterior)
 - $P(X|\theta)$: 似然 (Likelihood)
 - $P(\theta)$: 先验 (Prior)
 - $P(X) = \int P(X|\theta)P(\theta)d\theta$: 证据 (Evidence, 归一化常数)
 - 贝叶斯推断的核心在于求解后验分布。

1.2 贝叶斯推断 (Bayesian Inference)

给定数据集 $X = \{x_1, \dots, x_N\}$ 。

对于新样本 \hat{x} , 我们希望求出 $P(\hat{x}|X)$ (后验预测分布 Posterior Predictive Distribution)。

$$\begin{aligned} P(\hat{x}|X) &= \int_{\theta} P(\hat{x}, \theta|X) d\theta \\ &= \int_{\theta} P(\hat{x}|\theta) \cdot P(\theta|X) d\theta \\ &= E_{\theta|X}[P(\hat{x}|\theta)] \end{aligned} \tag{1}$$

即通过对参数 θ 的积分 (求期望) 来获得预测。

1.3 推断方法 (Inference Methods)

推断任务 (求后验或期望) 通常分为两类：

- 精确推断 (Exact Inference): 可以得到精确的后验分布 (例如共轭先验的情况)。
- 近似推断 (Approximate Inference): 当积分不可积或难以计算时使用。

- 确定性近似 (Deterministic Approximation) → 变分推断 (Variational Inference, VI)
- 本章重点
- 随机近似 (Stochastic Approximation) → MCMC (Markov Chain Monte Carlo) (例
如 MH 算法, Gibbs 采样)

1.4 期望最大化 (EM Algorithm)

EM 是一种基于优化的方法，常用于含有隐变量 Z 的模型参数估计。

- 目标: $\hat{\theta} = \arg \max \log P(X|\theta)$
- 更新步骤 (E-step & M-step 结合):
 $\theta^{(t+1)} = \arg \max_{\theta} \int_z \log P(X, z|\theta) \cdot P(z|X, \theta^{(t)}) dz$

2. 变分推断 (Variational Inference)

变分推断的核心思想是寻找一个分布 $q(Z)$ 来近似后验分布 $P(Z|X)$ 。

- X : Observed Data (观测数据)
- Z : Latent Variable + Parameter (隐变量 + 参数)
- (X, Z) : Complete Data (完整数据)

2.1 公式推导 (Formula Deduction)

我们从边缘似然 (Marginal Likelihood) $\log P(X)$ 出发。

由于涉及到隐变量 Z ，我们引入分布 $q(Z)$ ：

$$\log P(X) = \log P(X, Z) - \log P(Z|X) \quad (2)$$

推导 (Derivation):

根据条件概率公式 (Conditional Probability):

$$P(Z|X) = \frac{P(X, Z)}{P(X)}$$

移项得:

$$P(X) = \frac{P(X, Z)}{P(Z|X)}$$

两边取对数:

$$\log P(X) = \log \left(\frac{P(X, Z)}{P(Z|X)} \right) = \log P(X, Z) - \log P(Z|X)$$

两边同时对 $q(Z)$ 求期望 (积分)：

$$\begin{aligned} \text{左边} &= \int_Z q(Z) \log P(X) dZ = \log P(X) \cdot \int_Z q(Z) dZ = \log P(X) \\ \text{右边} &= \int_Z q(Z) \log \frac{P(X, Z)}{P(Z|X)} dZ \\ &= \int_Z q(Z) \log \frac{P(X, Z)}{q(Z)} \cdot \frac{q(Z)}{P(Z|X)} dZ \\ &= \underbrace{\int_Z q(Z) \log \frac{P(X, Z)}{q(Z)} dZ}_{\text{ELBO}} - \underbrace{\int_Z q(Z) \log \frac{P(Z|X)}{q(Z)} dZ}_{-\text{KL}(q||p)} \\ &= \mathcal{L}(q) + \text{KL}(q||P(Z|X)) \end{aligned} \quad (3)$$

其中:

1. **ELBO (Evidence Lower Bound, 证据下界):** $\mathcal{L}(q) = \int_Z q(Z) \log \frac{P(X, Z)}{q(Z)} dZ$
2. **KL 散度 (Kullback-Leibler Divergence):** $\text{KL}(q||P) = \int_Z q(Z) \log \frac{q(Z)}{P(Z|X)} dZ \geq 0$

因为 $\log P(X)$ 是常数 (相对于 q 而言), 且 $\text{KL} \geq 0$, 所以:

$$\log P(X) \geq \mathcal{L}(q) \quad (4)$$

要使 $q(Z) \approx P(Z|X)$ ，即最小化 $KL(q||P)$ ，等价于 **最大化 ELBO** $\mathcal{L}(q)$ 。

$$\hat{q}(Z) = \arg \max_{q(Z)} \mathcal{L}(q) \quad (5)$$

2.2 平均场理论 (Mean Field Theory)

为了求解 $q(Z)$ ，我们需要对其形式做假设。常用的假设是 **平均场假设 (Mean Field Assumption)**：

假设 Z 可以划分为 M 个独立的组 Z_1, Z_2, \dots, Z_M ，且它们之间相互独立：

$$q(Z) = \prod_{i=1}^M q_i(Z_i) \quad (6)$$

我们的目标是求解每一个 $q_j(Z_j)$ 。

将 $\mathcal{L}(q)$ 展开：

$$\begin{aligned} \mathcal{L}(q) &= \int_Z q(Z) \log P(X, Z) dZ - \int_Z q(Z) \log q(Z) dZ \\ &= \underbrace{\int_Z \left(\prod_{i=1}^M q_i(Z_i) \right) \log P(X, Z) dZ}_{\textcircled{1}} - \underbrace{\int_Z \left(\prod_{i=1}^M q_i(Z_i) \right) \sum_{i=1}^M \log q_i(Z_i) dZ}_{\textcircled{2}} \end{aligned} \quad (7)$$

分析第一项 ① (Term 1):

我们将积分分解为 Z_j 和 Z_{-j} (除 Z_j 以外的变量)：

$$\begin{aligned} \textcircled{1} &= \int_Z \left(\prod_{i=1}^M q_i(Z_i) \right) \log P(X, Z) dZ_1 dZ_2 \dots dZ_M \\ &= \int_{Z_j} q_j(Z_j) \left(\int_{Z_{-j}} \prod_{i \neq j} q_i(Z_i) \log P(X, Z) dZ_{\text{others}} \right) dZ_j \\ &= \int_{Z_j} q_j(Z_j) \underbrace{\left(\int_{Z_{-j}} \log P(X, Z) \cdot \prod_{i \neq j} q_i(Z_i) dZ_i \right)}_{E_{q_{-j}}[\log P(X, Z)]} dZ_j \\ &= \int_{Z_j} q_j(Z_j) \cdot E_{q_{-j}}[\log P(X, Z)] dZ_j \end{aligned} \quad (8)$$

这里 $E_{q_{-j}}$ 表示关于除 Z_j 以外所有变量的期望。

分析第二项 ② (Term 2):

这一项是熵 (Entropy) 形式。

$$\begin{aligned} \textcircled{2} &= \int_Z \left(\prod_{i=1}^M q_i(Z_i) \right) \log q(Z) dZ \\ &= \int_Z \prod_{i=1}^M q_i(Z_i) \cdot \sum_{i=1}^M \log q_i(Z_i) dZ \\ &= \int_Z \prod_{i=1}^M q_i(Z_i) [\log q_1(Z_1) + \dots + \log q_M(Z_M)] dZ \end{aligned} \quad (9)$$

考虑其中某一项 (例如 $\log q_1$)：

$$\begin{aligned} &\int_{Z_1 \dots Z_M} q_1 q_2 \dots q_M \log q_1 dZ_1 \dots dZ_M \\ &= \int_{Z_1} q_1 \log q_1 dZ_1 \cdot \underbrace{\int_{Z_2} q_2 dZ_2}_{1} \dots \underbrace{\int_{Z_M} q_M dZ_M}_{1} \\ &= \int_{Z_1} q_1 \log q_1 dZ_1 \end{aligned} \quad (10)$$

因此，总和可以保留 q_j 项，其余项相对于 q_j 是常数：

$$\textcircled{2} = \int_{Z_j} q_j(Z_j) \log q_j(Z_j) dZ_j + C \quad (11)$$

合并 ① - ② 关于 $q_j(Z_j)$ 的部分：

$$\mathcal{L}(q_j) = \int_{Z_j} q_j(Z_j) E_{q_{-j}}[\log P(X, Z)] dZ_j - \int_{Z_j} q_j(Z_j) \log q_j(Z_j) dZ_j + C \quad (12)$$

令 $\log \hat{P}(X, Z_j) = E_{q_{-j}}[\log P(X, Z)]$ ，则：

$$\begin{aligned} \mathcal{L}(q_j) &= \int_{Z_j} q_j(Z_j) \log \hat{P}(X, Z_j) dZ_j - \int_{Z_j} q_j(Z_j) \log q_j(Z_j) dZ_j + C \\ &= \int_{Z_j} q_j(Z_j) \log \frac{\hat{P}(X, Z_j)}{q_j(Z_j)} dZ_j + C \\ &= -\text{KL}(q_j || \hat{P}(X, Z_j)) + C \end{aligned} \quad (13)$$

因为 $\text{KL} \geq 0$ ，所以要最大化 $\mathcal{L}(q_j)$ ，必须要最小化 KL 散度，即 $\text{KL} = 0$ 。

这发生在两个分布相等时：

$$\log q_j^*(Z_j) = \log \hat{P}(X, Z_j) = E_{q_{-j}}[\log P(X, Z)] \quad (14)$$

因此：

$$q_j^*(Z_j) = \hat{P}(X, Z_j) \quad (15)$$

或者写成指数形式：

$$q_j^*(Z_j) \propto \exp \{E_{Z_{-j}}[\log P(X, Z)]\} \quad (16)$$

这就是 **坐标上升 (Coordinate Ascent)** 算法的更新公式。

我们固定其它 $q_{i \neq j}$ ，更新 q_j ，迭代进行直到收敛。

具体的迭代过程（以 M 个变量为例）：

$$\begin{aligned} \log \hat{q}_1(Z_1) &= E_{Z_2, \dots, Z_M}[\log P(X, Z)] \\ &= \int_{Z_2 \dots Z_M} \hat{q}_2(Z_2) \dots \hat{q}_M(Z_M) [\log P(X, Z)] dZ_2 \dots dZ_M \\ \log \hat{q}_2(Z_2) &= E_{Z_1, Z_3, \dots, Z_M}[\log P(X, Z)] \\ &= \int_{Z_1 Z_3 \dots Z_M} \hat{q}_1(Z_1) \hat{q}_3(Z_3) \dots \hat{q}_M(Z_M) [\log P(X, Z)] dZ_1 dZ_3 \dots dZ_M \\ &\vdots \\ \log \hat{q}_M(Z_M) &= E_{Z_1, \dots, Z_{M-1}}[\log P(X, Z)] \\ &= \int_{Z_1 \dots Z_{M-1}} \hat{q}_1(Z_1) \dots \hat{q}_{M-1}(Z_{M-1}) [\log P(X, Z)] dZ_1 \dots dZ_{M-1} \end{aligned} \quad (17)$$

每一次更新 q_j 时，都使用最新的其它 $q_{i \neq j}$ 分布。

3. 随机梯度变分推断 (Stochastic Gradient Variational Inference, SGVI)

回顾 ELBO 的定义：

$$\text{ELBO} = \mathcal{L}(\phi) = E_{q_\phi(z)} \left[\log \frac{P_\theta(x, z)}{q_\phi(z)} \right] \quad (18)$$

其中 x 是观测变量， z 是隐变量， ϕ 是变分分布 q 的参数， θ 是模型参数。

我们的目标是找到最优的 ϕ 使得 ELBO 最大化：

$$\hat{\phi} = \arg \max_{\phi} \mathcal{L}(\phi)$$

直接求导 $\nabla_{\phi} \mathcal{L}(\phi)$ 比较困难，因为期望分布 $q_{\phi}(z)$ 本身也包含参数 ϕ 。

3.1 梯度推导 (Gradient Deduction)

我们可以利用 **Log-Derivative Trick (对数导数技巧)** 来交换梯度和积分的顺序。

$$\begin{aligned}\nabla_{\phi} \mathcal{L}(\phi) &= \nabla_{\phi} \int q_{\phi}(z) [\log P_{\theta}(x, z) - \log q_{\phi}(z)] dz \\ &= \int \nabla_{\phi} q_{\phi}(z) [\log P_{\theta}(x, z) - \log q_{\phi}(z)] dz + \int q_{\phi}(z) \nabla_{\phi} [\log P_{\theta}(x, z) - \log q_{\phi}(z)] dz\end{aligned}\quad (19)$$

第一项 (Term 1):

利用 $\nabla_{\phi} q_{\phi}(z) = q_{\phi}(z) \nabla_{\phi} \log q_{\phi}(z)$:

$$\text{Term 1} = \int q_{\phi}(z) \nabla_{\phi} \log q_{\phi}(z) [\log P_{\theta}(x, z) - \log q_{\phi}(z)] dz \quad (20)$$

这可以写成期望形式: $E_{q_{\phi}(z)} [\nabla_{\phi} \log q_{\phi}(z) (\log P_{\theta}(x, z) - \log q_{\phi}(z))]$ 。

第二项 (Term 2):

$$\begin{aligned}\text{Term 2} &= \int q_{\phi}(z) \nabla_{\phi} [\log P_{\theta}(x, z) - \log q_{\phi}(z)] dz \\ &= \int q_{\phi}(z) \left(0 - \frac{1}{q_{\phi}(z)} \nabla_{\phi} q_{\phi}(z) \right) dz \\ &= - \int \nabla_{\phi} q_{\phi}(z) dz = - \nabla_{\phi} \int q_{\phi}(z) dz = - \nabla_{\phi} 1 = 0\end{aligned}\quad (21)$$

(注意: $\log P_{\theta}(x, z)$ 对 ϕ 求导为 0)

结论:

$$\nabla_{\phi} \mathcal{L}(\phi) = E_{q_{\phi}(z)} [\nabla_{\phi} \log q_{\phi}(z) (\log P_{\theta}(x, z) - \log q_{\phi}(z))] \quad (22)$$

这被称为 **Score Function Estimator** (或是 REINFORCE 梯度)。

3.2 蒙特卡洛近似 (Monte Carlo Approximation)

通过从 $q_{\phi}(z)$ 中采样 L 个样本 $z^{(l)} \sim q_{\phi}(z), l = 1, \dots, L$, 我们可以近似上述期望:

$$\nabla_{\phi} \mathcal{L}(\phi) \approx \frac{1}{L} \sum_{l=1}^L \nabla_{\phi} \log q_{\phi}(z^{(l)}) \left(\log P_{\theta}(x, z^{(l)}) - \log q_{\phi}(z^{(l)}) \right) \quad (23)$$

这样我们就可以使用随机梯度上升 (Stochastic Gradient Ascent) 来优化 ϕ 。

3.3 重参数化技巧 (Reparameterization Trick)

问题 (Problem):

前面提到的 Score Function Estimator (REINFORCE) 虽然是无偏估计, 但是方差很大 (High Variance), 导致训练不稳定。

解决方案 (Solution):

通过重参数化技巧 (Reparameterization Trick) 来降低方差。

假设隐变量 z 可以表示为一个无参数分布的辅助变量 ϵ 的确定性变换:

$$z = g_{\phi}(\epsilon, x^{(i)}) \quad \text{其中} \quad \epsilon \sim p(\epsilon)$$

例如:

- 如果 $q_{\phi}(z|x) = \mathcal{N}(z; \mu, \sigma^2)$, 则 $z = \mu + \sigma \cdot \epsilon$, 其中 $\epsilon \sim \mathcal{N}(0, I)$ 。

梯度推导:

利用重参数化, 期望中的分布不再依赖于 ϕ , 我们可以将梯度算子直接移入期望内部:

$$\begin{aligned}
\nabla_{\phi} \mathcal{L}(\phi) &= \nabla_{\phi} E_{q_{\phi}(z)} [\log P_{\theta}(x^{(i)}, z) - \log q_{\phi}(z|x^{(i)})] \\
&= \nabla_{\phi} E_{p(\epsilon)} [\log P_{\theta}(x^{(i)}, g_{\phi}(\epsilon, x^{(i)})) - \log q_{\phi}(g_{\phi}(\epsilon, x^{(i)})|x^{(i)})] \\
&= E_{p(\epsilon)} [\nabla_{\phi} (\log P_{\theta}(x^{(i)}, z) - \log q_{\phi}(z|x^{(i)}))] \\
&= E_{p(\epsilon)} [\nabla_z (\log P_{\theta}(x^{(i)}, z) - \log q_{\phi}(z|x^{(i)})) \cdot \nabla_{\phi} g_{\phi}(\epsilon, x^{(i)})]
\end{aligned} \tag{24}$$

蒙特卡洛估计:

采样 L 个噪声样本 $\epsilon^{(l)} \sim p(\epsilon)$, 计算梯度:

$$\nabla_{\phi} \mathcal{L}(\phi) \approx \frac{1}{L} \sum_{l=1}^L \nabla_z \left(\log P_{\theta}(x^{(i)}, z^{(l)}) - \log q_{\phi}(z^{(l)}|x^{(i)}) \right) \cdot \nabla_{\phi} g_{\phi}(\epsilon^{(l)}, x^{(i)}) \tag{25}$$

其中 $z^{(l)} = g_{\phi}(\epsilon^{(l)}, x^{(i)})$ 。

3.4 SGVI 算法

基于随机梯度的变分推断算法 (Stochastic Gradient Variational Inference):

$$\phi^{(t+1)} \leftarrow \phi^{(t)} + \lambda^{(t)} \cdot \nabla_{\phi} \mathcal{L}(\phi) \tag{26}$$

其中 $\lambda^{(t)}$ 是学习率 (Learning Rate) 或步长 (Step Size)。